

- Dlaczego MLFlow jest użyteczne?
MLFlow upraszcza zarządzanie cyklem życia modeli ML, oferując narzędzia do śledzenia eksperymentów, pakowania kodu i wdrażania modeli.
- Jaki jest cel posiadania zautomatyzowanych pipeline'ów w środowisku produkcyjnym ML?
Zautomatyzowane pipeline'y zapewniają powtarzalność, skalowalność i efektywność, ułatwiając wdrażanie, testowanie i utrzymanie modeli ML w produkcji. Poleganie na ręcznych notatnikach wprowadza ryzyko błędów i niejednoznaczności.
- Jaka jest różnica między A/B testing, Green/Blue deployments, Canary deployments i Challenger/Champion deployments?
- A/B Testing: Porównuje dwie wersje modelu, aby sprawdzić, która działa lepiej.
- Green/Blue Deployments: Jedna wersja (Blue) jest aktywna, a Green jest testowane, po czym następuje przełączenie.
- Canary Deployments: Stopniowe wdrażanie nowej wersji modelu do małej grupy, zanim zostanie wdrożona na szeroką skalę.
- Challenger/Champion: Jeden model (Champion) jest aktywny, a nowy model (Challenger) jest testowany równolegle.
- Dlaczego przechowujemy artefakty w AWS S3, a metadane w RDS?
AWS S3 zapewnia skalowalną i bezpieczną przestrzeń do przechowywania dużych artefaktów, podczas gdy RDS oferuje niezawodne, strukturalne przechowywanie metadanych, umożliwiając efektywne zapytania i zarządzanie.
- Jakie są zagrożenia i wyzwania związane z używaniem sekretów i kluczy API do uwierzytelniania instancji workflow w GitHub Actions?
Sekrety i klucze API mogą zostać ujawnione, jeśli nie są odpowiednio zarządzane, co stwarza ryzyko nieautoryzowanego dostępu. Wyzwania to zabezpieczenie danych uwierzytelniających, ich regularna rotacja i zapobieganie przypadkowemu ujawnieniu w logach lub kodzie.
- Jaki był największy problem przy realizacji zadania?
Największym wyzwaniem było zapewnienie płynnej integracji między różnymi narzędziami (MLFlow, AWS, GitHub) oraz zarządzanie zależnościami w różnych środowiskach.